

理论计算机科学导引

电子化讲义

Huijiao

2026 年 8 月 4 日

目录

第 1 讲 引子	1
1.1 二进制串与编码	1
1.2 可数集合	3
1.3 问题比程序多	3

第 1 讲 引子

理论计算机科学经常把两个层面分开讨论：函数（function）描述要计算什么，是问题的规格；程序（program）描述如何计算，是规格的一种实现。本讲先用二进制串形式化“描述”，再比较函数与程序在数量上的差异。

全文约定

$$\mathbb{N} = \{0, 1, 2, \dots\}, \quad \Sigma = \{0, 1\}.$$

1.1 二进制串与编码

定义 1.1 (二进制串). 对任意 $n \in \mathbb{N}$, 定义

$$\Sigma^n = \{(a_1, \dots, a_n) : a_i \in \Sigma\}.$$

特别地, $\Sigma^0 = \{\varepsilon\}$, 其中 ε 表示空串。所有有限二进制串的集合记为

$$\Sigma^* = \bigcup_{n \geq 0} \Sigma^n,$$

非空二进制串的集合记为 $\Sigma^+ = \Sigma^* \setminus \{\varepsilon\}$ 。若 $x \in \Sigma^n$, 则称 x 的长度为 $|x| = n$ 。

对 $x, y \in \Sigma^*$, 把二者的串联记为 xy 。若存在 $z \in \Sigma^*$ 使 $y = xz$, 则称 x 是 y 的前缀；若还能取到 $z \neq \varepsilon$, 则称 x 是 y 的真前缀。

定义 1.2 (编码). 集合 A 上的一个（二进制）编码是单射

$$E : A \longrightarrow \Sigma^*.$$

单射条件保证每个码字至多对应 A 中的一个对象，因而解码时不会混淆。

例 1.1 (直接串联可能产生歧义). 令 $b(n)$ 为自然数 n 的标准二进制表示，并尝试用

$$P(a, b) = b(a)b(b)$$

编码 $\mathbb{N} \times \mathbb{N}$ 。这个映射不是单射。例如

$$P(1, 6) = 1\ 110 = 1110 = 11\ 10 = P(3, 2).$$

问题在于直接串联后无法确定两个分量的分界位置。

定义 1.3 (无前缀编码). 编码 $E : A \rightarrow \Sigma^+$ 称为无前缀的 (prefix-free), 如果对任意不同的 $x, y \in A$, $E(x)$ 都不是 $E(y)$ 的前缀。

这里要求码字非空不是多余的: 如果唯一的码字是 ε , 那么串联任意多个码字都仍然得到 ε , 不可能唯一解码。

记 A^* 为由 A 中元素组成的所有有限序列的集合, 其空序列仍记为 ε 。对映射 $E : A \rightarrow \Sigma^*$, 定义其逐项串联扩张

$$\bar{E}(a_1, \dots, a_n) = \begin{cases} E(a_1) \cdots E(a_n), & n > 0, \\ \varepsilon, & n = 0. \end{cases} \quad (1.1)$$

定理 1.1 (无前缀编码的唯一可解码性). 若 $E : A \rightarrow \Sigma^+$ 是无前缀编码, 则由式 (1.1) 定义的 $\bar{E} : A^* \rightarrow \Sigma^*$ 是单射。

证明. 假设

$$\bar{E}(a_1, \dots, a_p) = \bar{E}(b_1, \dots, b_q).$$

因为每个码字非空, 等式一侧为空串当且仅当对应序列为空; 故只需考虑 $p, q > 0$ 的情形。两个相等的串分别以 $E(a_1)$ 和 $E(b_1)$ 开头, 因此 $E(a_1)$ 与 $E(b_1)$ 中较短者必为较长者的前缀。由无前缀性可知 $E(a_1) = E(b_1)$, 再由 E 的单射性得到 $a_1 = b_1$ 。

从等式两侧消去相同的首个码字并重复上述论证, 最终得到 $p = q$ 且 $a_i = b_i$ ($1 \leq i \leq p$)。因此 $\bar{E}$ 是单射。□

定理 1.2 (编码的无前缀化). 若存在编码 $E : A \rightarrow \Sigma^*$, 则存在无前缀编码 $E_{\text{pf}} : A \rightarrow \Sigma^+$, 并且对每个 $a \in A$ 都有

$$|E_{\text{pf}}(a)| = 2|E(a)| + 2.$$

证明. 先定义 $h(0) = 00$ 、 $h(1) = 11$, 并令 h 在串上逐位作用。取

$$E_{\text{pf}}(a) = h(E(a))01.$$

其长度显然为 $2|E(a)| + 2$ 。

把 $E_{\text{pf}}(a)$ 从左到右按两个比特一组切分: 最后一组是 01, 此前每一组只能是 00 或 11。假设 $E_{\text{pf}}(a)$ 是 $E_{\text{pf}}(b)$ 的前缀。由于两个串的长度都是偶数, 短串结尾的 01 与长串中的某个完整二比特组对齐; 它不可能等于长串正文中的 00 或 11, 所以只能与长串末尾的 01 对齐。因而两个码字等长且相等。逐组解码可得 $E(a) = E(b)$, 再由 E 的单射性得 $a = b$ 。所以不存在一个码字是另一个不同码字的前缀。□

注. 原稿进一步询问能否把长度开销改进到 $|E(a)| + O(\log|E(a)|)$ 。答案是肯定的。令 $n = |E(a)|$, 先用自定界格式

$$1^\ell 0 \text{ bin}(n+1), \quad \ell = |\text{bin}(n+1)|,$$

写出长度，再接上 $E(a)$ 。解码器先由连续的 1 得到 ℓ ，继而读出 $n+1$ ，最后恰好读取 n 位正文。所得码长为

$$n + 2\lfloor \log_2(n+1) \rfloor + 3 = n + O(\log(n+1)),$$

且构造仍然无前缀。

推论 1.1. 若存在编码 $E: A \rightarrow \Sigma^*$ ，则存在编码 $F: A^* \rightarrow \Sigma^*$ 。

证明. 先用[定理 1.2](#)把 E 无前缀化，再用[定理 1.1](#)逐项串联即可。□

1.2 可数集合

定义 1.4 (至多可数). 若存在单射 $f: A \rightarrow \mathbb{N}$ ，则称集合 A 是至多可数的。这等价于 A 有限或 A 与 $\mathbb{N}$ 之间存在双射。若 $A \neq \emptyset$ ，它也等价于存在满射 $g: \mathbb{N} \rightarrow A$ 。

注. 非空条件只影响最后一种表述：不存在从 $\mathbb{N}$ 到空集的函数，但空集显然是至多可数的。部分文献把“可数”专指与 $\mathbb{N}$ 等势，把本文的“至多可数”称作“可数”；使用时应先确认约定。

引理 1.1. Σ^* 是可数无限集。

证明. 对长度为 n 的二进制串 x ，令 $\text{val}_2(x)$ 表示允许前导零时的二进制数值，并定义

$$\nu(x) = 2^n - 1 + \text{val}_2(x).$$

长度为 n 的串恰好映到区间 $\{2^n - 1, \dots, 2^{n+1} - 2\}$ ；这些区间互不相交且覆盖 $\mathbb{N}$ 。因此 $\nu: \Sigma^* \rightarrow \mathbb{N}$ 是双射。□

定理 1.3 (可编码性与可数性). 集合 A 至多可数，当且仅当存在编码 $E: A \rightarrow \Sigma^*$ 。

证明. 若 $E: A \rightarrow \Sigma^*$ 是编码，则把它与[引理 1.1](#)中的单射 $\nu: \Sigma^* \rightarrow \mathbb{N}$ 复合，便得到 $A \rightarrow \mathbb{N}$ 的单射，所以 A 至多可数。

反之，若 $f: A \rightarrow \mathbb{N}$ 是单射，则把 f 与映射 $n \mapsto 1^n 0$ 复合，得到 $A \rightarrow \Sigma^*$ 的单射，也就是一个编码。□

1.3 问题比程序多

定义 1.5 (问题). 在本讲义中，一个（计算）问题是函数

$$f: \Sigma^* \longrightarrow \Sigma^*.$$

所有问题构成的集合记为

$$\mathcal{P} = (\Sigma^*)^{\Sigma^*}.$$

定理 1.4. 问题集合 $\mathcal{P}$ 不可数。

证明 (Cantor 对角化)。由引理 1.1, 可将所有输入依次写成 $s_0, s_1, s_2, \dots$ 。假设所有问题也能被序列 $f_0, f_1, f_2, \dots$ 穷尽。构造新问题 $g: \Sigma^* \rightarrow \Sigma^*$:

$$g(s_i) = \begin{cases} 0, & f_i(s_i) \neq 0, \\ 1, & f_i(s_i) = 0. \end{cases}$$

对每个 $i \in \mathbb{N}$ 都有 $g(s_i) \neq f_i(s_i)$, 所以 $g \neq f_i$ 。这与该序列穷尽所有问题的假设矛盾。因此 $\mathcal{P}$ 不可数。 $\square$

推论 1.2. 如果程序集合存在一个有限二进制编码, 并且每个程序至多实现一个问题, 那么存在没有任何程序能够实现的问题。

证明。由定理 1.3, 所有程序构成至多可数集, 因而程序能实现的问题也至多可数; 但定理 1.4 说明全部问题的集合不可数。 $\square$