

理论计算机科学导引

Lecture Note

Huijiao

2026 年 8 月 5 日

目录

第 1 章 引子	1
1.1 二进制串与编码	1
1.2 可数集合	3
1.3 问题的公理化定义	4
第 2 章 布尔电路	5
2.1 电路模型	5
2.2 AON-Circ 程序与 NAND 门	5
2.3 任意布尔函数的电路实现	6
2.3.1 NAND-Circ 程序中的语法糖 (syntactic sugar)	7
2.3.2 ADD 与 LOOKUP	7
2.3.3 精细上界	9
2.3.4 计数下界	10
2.4 程序编码与通用求值	11
第 3 章 布尔函数与语言	13
3.1 从一般函数到布尔函数	13
3.2 语言与布尔函数	14
第 4 章 自动机	15
4.1 确定有限自动机	15
4.2 正则语言的封闭性	16
4.3 非确定有限自动机	17
4.3.1 NFA 与 DFA 的等价性	18
4.3.2 拼接与 Kleene 星	18
4.4 正则表达式	19

第 1 章 引子

理论计算机科学经常把两个层面分开讨论：函数 (function) 描述要计算什么，是问题的规格；程序 (program) 描述如何计算，是规格的一种实现。从函数到程序，就是把抽象的东西具体化。本讲先用二进制串 (binary string) 形式化“描述”，再比较函数与程序在数量上的差异。

全文约定

$$\mathbb{N} = \{0, 1, 2, \dots\}, \quad \Sigma = \{0, 1\}.$$

1.1 二进制串与编码

定义 1.1 (二进制串). 对任意 $n \in \mathbb{N}$, 定义

$$\Sigma^n = \{(a_1, \dots, a_n) : a_i \in \Sigma\}.$$

特别地, $\Sigma^0 = \{\varepsilon\}$, 其中 ε 表示空串 (empty string)。记

$$\Sigma^* = \bigcup_{n \geq 0} \Sigma^n, \quad \Sigma^+ = \Sigma^* \setminus \{\varepsilon\}.$$

对 $x \in \Sigma^n$, 记其长度为 $|x| = n$ 。

对 $x, y \in \Sigma^*$, 把二者的串联记为 xy 。如果存在 $z \in \Sigma^*$ 使得 $y = xz$, 则称 x 是 y 的前缀 (prefix)。如果还能取到 $z \neq \varepsilon$, 则称 x 是 y 的真前缀 (proper prefix)。

定义 1.2 (编码). 集合 A 上的一个 (二进制) 编码 (encoding) 是单射 (injective map)

$$E : A \longrightarrow \Sigma^*.$$

这里, 单射是指: 对任意 $x, y \in A$, 若 $E(x) = E(y)$, 则 $x = y$ 。

例 1.1. 令 $b(n)$ 为自然数 n 的标准二进制表示, 并尝试用

$$P(a, b) = b(a)b(b)$$

编码 $\mathbb{N} \times \mathbb{N}$ 。这个映射不是单射。例如

$$P(1, 6) = 1\ 110 = 1110 = 11\ 10 = P(3, 2).$$

问题在于直接串联后无法确定两个分量的分界位置。因此我们要考虑一种更优秀的编码, 来避免这个问题。

定义 1.3 (无前缀编码). 编码 $E: A \rightarrow \Sigma^+$ 称为无前缀的 (prefix-free), 如果对任意不同的 $x, y \in A$, 码字 $E(x)$ 都不是 $E(y)$ 的前缀。

记 A^* 为由 A 中元素组成的所有有限序列的集合, 其空序列仍记为 ε 。对映射 $E: A \rightarrow \Sigma^*$, 定义其逐项串联扩张

$$\overline{E}(a_1, \dots, a_n) = \begin{cases} E(a_1) \cdots E(a_n), & n > 0, \\ \varepsilon, & n = 0. \end{cases} \quad (1.1)$$

这个定义很自然, 我们要说明这个自然定义确实是个单射。

引理 1.1. 若 $E: A \rightarrow \Sigma^+$ 是无前缀编码, 则由 式 (1.1) 定义的 $\overline{E}: A^* \rightarrow \Sigma^*$ 是单射。

证明. 假设两组序列的编码相同:

$$\overline{E}(a_1, \dots, a_p) = \overline{E}(b_1, \dots, b_q).$$

码字非空, 所以 $p = 0 \iff q = 0$ 。若 $p, q > 0$, 则 $E(a_1)$ 与 $E(b_1)$ 中较短的码字一定是较长码字的前缀。由无前缀性可知

$$E(a_1) = E(b_1) \implies a_1 = b_1.$$

两边消去首个码字并归纳, 得到

$$p = q, \quad a_i = b_i \quad (1 \leq i \leq p).$$

故 $\overline{E}$ 是单射。 □

定理 1.1 (编码的无前缀化). 若存在编码 $E: A \rightarrow \Sigma^*$, 则存在无前缀编码 $E_{\text{pf}}: A \rightarrow \Sigma^+$, 并且对每个 $a \in A$ 都有

$$|E_{\text{pf}}(a)| = 2|E(a)| + 2.$$

证明. 定义 $h(0) = 00$ 、 $h(1) = 11$, 并令 h 逐位作用于二进制串。取

$$E_{\text{pf}}(a) = h(E(a))01, \quad |E_{\text{pf}}(a)| = 2|E(a)| + 2.$$

按两个比特分组时, 正文块属于 $\{00, 11\}$, 终止块为 01 。若 $E_{\text{pf}}(a)$ 是 $E_{\text{pf}}(b)$ 的前缀, 则短串的终止块必须与长串的某一块对齐。正文中没有 01 , 故它只能与长串的终止块对齐。于是

$$E_{\text{pf}}(a) = E_{\text{pf}}(b) \implies E(a) = E(b) \implies a = b.$$

因此 E_{pf} 无前缀。 □

思考题. 能否把长度开销改进到 $|E(a)| + O(\log|E(a)|)$?

解答. 可以. 令

$$n = |E(a)|, \quad \ell = |\text{bin}(n+1)|,$$

并定义

$$L(n) = 1^\ell 0 \text{ bin}(n+1), \quad E'(a) = L(n)E(a).$$

解码过程为

$$1^\ell 0 \longrightarrow \ell \longrightarrow \text{bin}(n+1) \longrightarrow n \longrightarrow E(a).$$

其中最后一步恰好读取 n 位. 并且

$$|E'(a)| = n + 2\lfloor \log_2(n+1) \rfloor + 3 = n + O(\log(n+1)).$$

$L(n)$ 自定界; 当 n 相同时, $E'(a)$ 等长. 因此该构造无前缀. $\square$

推论 1.1. 若存在编码 $E: A \rightarrow \Sigma^*$, 则存在编码 $F: A^* \rightarrow \Sigma^*$.

证明. 先用定理 1.1 把 E 无前缀化, 再用引理 1.1 逐项串联即可. $\square$

1.2 可数集合

定义 1.4 (至多可数). 如果存在单射 $f: A \rightarrow \mathbb{N}$, 则称集合 A 是至多可数的 (at most countable). 换言之, A 或者是有限集, 或者可以与自然数集 $\mathbb{N}$ 建立双射 (bijection). 当 $A \neq \emptyset$ 时, 这也等价于存在满射 (surjection) $g: \mathbb{N} \rightarrow A$.

注. 非空条件只用于满射表述, 因为不存在 $\mathbb{N} \rightarrow \emptyset$. 有些文献把本文的“至多可数”简称为“可数”.

引理 1.2. Σ^* 是可数无限集.

证明. 对 $x \in \Sigma^n$, 令 $\text{val}_2(x)$ 为其二进制数值 (允许前导零), 并定义

$$\nu(x) = 2^n - 1 + \text{val}_2(x).$$

于是

$$\nu(\Sigma^n) = \{2^n - 1, \dots, 2^{n+1} - 2\}, \quad \mathbb{N} = \bigsqcup_{n \geq 0} \nu(\Sigma^n).$$

故 $\nu: \Sigma^* \rightarrow \mathbb{N}$ 是双射. $\square$

定理 1.2 (可编码性与可数性). 集合 A 至多可数, 当且仅当存在编码 $E: A \rightarrow \Sigma^*$.

证明. 由引理 1.2, 存在双射 $\nu: \Sigma^* \rightarrow \mathbb{N}$.

若 $E: A \rightarrow \Sigma^*$ 是单射, 则

$$\nu \circ E: A \rightarrow \mathbb{N}$$

也是单射. 反之, 若 $f: A \rightarrow \mathbb{N}$ 是单射, 令 $c(n) = 1^n 0$, 则

$$c \circ f: A \rightarrow \Sigma^*$$

是一个编码. $\square$

1.3 问题的公理化定义

因为我们已经有编码了，所以我们可以把问题公理化了。

定义 1.5 (问题). 在本讲义中，一个 (计算) 问题 (computational problem) 是函数

$$f : \Sigma^* \longrightarrow \Sigma^*.$$

所有问题构成的集合记为

$$\mathcal{P} = (\Sigma^*)^{\Sigma^*}.$$

定理 1.3. 问题集合 $\mathcal{P}$ 不可数。

证明 (*Cantor* 对角化). 由[引理 1.2](#), 可写

$$\Sigma^* = \{s_0, s_1, s_2, \dots\}.$$

反设 $\mathcal{P} = \{f_0, f_1, f_2, \dots\}$ 。定义

$$g(s_i) = \begin{cases} 0, & f_i(s_i) \neq 0, \\ 1, & f_i(s_i) = 0. \end{cases}$$

因而

$$\forall i \in \mathbb{N}, \quad g(s_i) \neq f_i(s_i) \implies g \neq f_i.$$

于是 $g \in \mathcal{P}$ 却不在上述枚举中，矛盾。

□

第 2 章 布尔电路

布尔电路 (Boolean circuit) 用有限个逻辑门 (logic gate) 把输入比特 (bit) 变成输出比特。本讲使用三种基本逻辑门: 与门 (AND)、或门 (OR) 和非门 (NOT)。

2.1 电路模型

一个布尔电路 C 可以看成有限的有向无环图 (directed acyclic graph, DAG)。图中包含:

1. n 个输入结点 $x_0, \dots, x_{n-1}$;
2. 若干内部结点, 每个结点标记为 AND、OR 或 NOT 门;
3. m 个指定的输出结点 $y_0, \dots, y_{m-1}$ 。

AND 和 OR 门各有两个输入, NOT 门有一个输入。因为图中没有有向环, 所以各个门可以按拓扑顺序 (topological order) 依次求值。电路的规模 (size) 是其中逻辑门的数量, 记为 $|C|$ 。

定义 2.1 (电路计算). 设 $f: \{0, 1\}^n \rightarrow \{0, 1\}^m$ 。如果对每个输入 $x \in \{0, 1\}^n$, 电路 C 的 m 个输出比特恰好组成 $f(x)$, 则称 C 计算函数 f 。

例 2.1. 异或函数 (exclusive OR, XOR) 可以写成

$$\text{XOR}(a, b) = \neg(a \wedge b) \wedge (a \vee b),$$

因而可以用 AND、OR 和 NOT 门组成的布尔电路计算。

2.2 AON-Circ 程序与 NAND 门

定义 2.2 (AON-Circ 程序). AON-Circ 程序是一列按顺序执行的赋值语句 (assignment statement)。每条语句调用一次 AND、OR 或 NOT, 并且只能读取输入变量或此前语句已经算出的变量。程序最后指定 m 个变量作为输出。程序的规模是赋值语句的行数。

例如，一条语句可以具有以下三种形式之一：

$$z_i \leftarrow z_j \wedge z_k, \quad z_i \leftarrow z_j \vee z_k, \quad z_i \leftarrow \neg z_j,$$

其中右侧的变量必须已经定义。

定理 2.1. 函数 f 能由布尔电路计算，当且仅当它能由 *AON-Circ* 程序计算。两种表示可以保持规模不变：电路的门数等于对应程序的行数。

证明. 给定电路，按拓扑顺序为每个门写一条赋值语句，即得到 *AON-Circ* 程序。反过来，为程序的每一行建立一个门，并把该行读取的变量连接到这个门，即得到布尔电路。每个门与每行语句一一对应。□

与非门 (NAND) 定义为

$$\text{NAND}(a, b) = \neg(a \wedge b).$$

只使用 NAND 门便可实现三个基本门：

$$\begin{aligned} \neg a &= \text{NAND}(a, a), \\ a \wedge b &= \text{NAND}(\text{NAND}(a, b), \text{NAND}(a, b)), \\ a \vee b &= \text{NAND}(\text{NAND}(a, a), \text{NAND}(b, b)). \end{aligned}$$

因此 NAND 电路与普通布尔电路可以相互转换。若原电路规模为 s ，则转换后分别满足

$$|C_{\text{AON}}| \leq 2|C_{\text{NAND}}|, \quad |C_{\text{NAND}}| \leq 3|C_{\text{AON}}|.$$

2.3 任意布尔函数的电路实现

定理 2.2. 对任意 $n, m \geq 1$ 以及任意函数

$$f : \{0, 1\}^n \longrightarrow \{0, 1\}^m,$$

都存在计算 f 的布尔电路。进一步，电路规模可以达到

$$|C| = O\left(\frac{m2^n}{n}\right).$$

粗略上界的构造. 先考虑 f 的第 j 个输出比特 f_j 。对每个 $a = (a_0, \dots, a_{n-1}) \in \{0, 1\}^n$ ，定义

$$T_a(x) = \bigwedge_{r=0}^{n-1} \ell_{a,r}(x_r), \quad \ell_{a,r}(x_r) = \begin{cases} x_r, & a_r = 1, \\ \neg x_r, & a_r = 0. \end{cases}$$

当且仅当 $x = a$ 时, $T_a(x) = 1$ 。因此

$$f_j(x) = \bigvee_{\substack{a \in \{0,1\}^n \\ f_j(a)=1}} T_a(x).$$

这就是析取范式 (disjunctive normal form, DNF) 的直接构造。每个 T_a 使用 $O(n)$ 个门, 而这样的项至多有 2^n 个, 所以一个输出比特需要 $O(n2^n)$ 个门。分别构造 m 个输出, 便得到

$$|C| = O(mn2^n).$$

[定理 2.2](#) 中的 $O(m2^n/n)$ 上界去掉了这个直接构造中的冗余。这个更精细的上界将在后文证明。

定义 2.3 (通用门组). 如果只使用门集合 $\mathcal{F}$ 中的门就能计算任意布尔函数, 则称 $\mathcal{F}$ 是通用的 (universal)。

由 [定理 2.2](#) 和上面的三个恒等式, NAND 门本身就是通用的。因此, 要判断一组门 $\mathcal{F}$ 是否通用, 只需判断能否仅用 $\mathcal{F}$ 中的门实现 NAND 函数。

为了证明 [定理 2.2](#), 我们先来介绍一些特性和例子。

2.3.1 NAND-Circ 程序中的语法糖 (syntactic sugar)

为了让程序更容易书写, 可以暂时加入以下三种语法糖:

1. **定长循环 (fixed-length loop)**: 把循环体复制固定次数;
2. **用户定义过程 (user-defined procedure)**: 在调用处展开过程体;
3. **条件语句 (conditional statement)**: 同时计算两个分支, 再用选择器 (multiplexer, MUX) 输出其中一个。

条件语句中的一比特选择器可以写成

$$\text{MUX}(b, u, v) = (\neg b \wedge u) \vee (b \wedge v),$$

其中 $b = 0$ 时输出 u , $b = 1$ 时输出 v 。循环次数和过程参数一旦固定, 上述写法都能展开成普通的 NAND-Circ 程序, 因此不会增强计算能力。

2.3.2 ADD 与 LOOKUP

例 2.2 (ADD). 输入包含两个 n 位二进制数。按从低位到高位顺序, 将它们分别记为

$$(x_0, \dots, x_{n-1}), \quad (x_n, \dots, x_{2n-1})$$

加法函数为

$$\text{ADD}_n : \{0, 1\}^{2n} \longrightarrow \{0, 1\}^{n+1}.$$

令 $\text{MAJ}(a, b, c)$ 表示三个比特的多数值 (majority), 即

$$\text{MAJ}(a, b, c) = (a \wedge b) \vee (a \wedge c) \vee (b \wedge c).$$

可以用如下定长循环实现逐位进位加法:

```
result = [0] * (n + 1)
carry = [0] * (n + 1)
for i in range(n):
    result[i] = XOR(carry[i], XOR(x[i], x[i+n]))
    carry[i+1] = MAJ(carry[i], x[i], x[i+n])
result[n] = carry[n]
return result
```

XOR 和 MAJ 都能用常数个 NAND 门实现。把循环展开后, 程序共有 $O(n)$ 行, 因而加法电路的规模为 $O(n)$ 。

例 2.3 (LOOKUP). 输入由 2^k 个数据比特 $x_0, \dots, x_{2^k-1}$ 和 k 个索引比特 $i_0, \dots, i_{k-1}$ 组成。令

$$j = \sum_{r=0}^{k-1} i_r 2^{k-1-r}.$$

查表函数 (lookup function) 返回第 j 个数据比特:

$$\text{LOOKUP}_k : \{0, 1\}^{2^k+k} \longrightarrow \{0, 1\}, \quad \text{LOOKUP}_k(x, i) = x_j.$$

它可以递归地把数据表分成两半:

```
lookup(x, index):
    if len(index) == 1:
        if index[0] == 0: return x[0]
        else: return x[1]
    half = len(x) / 2
    if index[0] == 0:
        return lookup(x[0:half], index[1:])
    else:
        return lookup(x[half:], index[1:])
```

对电路而言, 条件语句的两个分支都要构造, 再由 MUX 选择输出。若 $L(k)$ 表示展开后的程序行数, 则

$$L(k) = 2L(k-1) + O(1), \quad L(1) = O(1).$$

因此 $L(k) = O(2^k)$, LOOKUP 电路的规模也是 $O(2^k)$ 。

2.3.3 精细上界

定理 2.2 的精细上界证明. 先考虑单输出函数 $f: \{0, 1\}^n \rightarrow \{0, 1\}$. 取 $k < n$, 并把输入写成

$$x = (u, v), \quad u \in \{0, 1\}^k, \quad v \in \{0, 1\}^{n-k}.$$

对每个 $v \in \{0, 1\}^{n-k}$, 定义 k 元函数

$$h_v(u) = f(u, v).$$

先共享地构造全部 2^k 个最小项 (minterm)

$$M_a(u) = \bigwedge_{r=0}^{k-1} \begin{cases} u_r, & a_r = 1, \\ \neg u_r, & a_r = 0, \end{cases} \quad a \in \{0, 1\}^k,$$

代价为 $O(k2^k)$. 任意函数 $h: \{0, 1\}^k \rightarrow \{0, 1\}$ 都可以写成

$$h(u) = \bigvee_{\substack{a \in \{0, 1\}^k \\ h(a)=1}} M_a(u),$$

因此, 在最小项已经构造好的前提下, 每个 h 只需额外 $O(2^k)$ 个门. k 元布尔函数总共只有 2^{2^k} 种, 所以全部不同的 h_v 可以用

$$O(k2^k + 2^{2^k} 2^k)$$

个门计算. 重复出现的 h_v 直接复用同一根输出线. 由此得到真值表 (truth table) 的一整行

$$G(u) = (h_v(u))_{v \in \{0, 1\}^{n-k}} \in \{0, 1\}^{2^{n-k}}.$$

最后用 v 查表:

$$f(u, v) = \text{LOOKUP}_{n-k}(G(u), v).$$

由 **例 2.3**, 这一步需要 $O(2^{n-k})$ 个门. 总规模为

$$O(k2^k + 2^{2^k} 2^k + 2^{n-k}). \quad (2.1)$$

对充分大的 n , 令 $d = n - 2 \log_2 n$, 并选择整数 k 使得

$$\frac{d}{2} < 2^k \leq d.$$

于是

$$2^{2^k} 2^k \leq \frac{2^n}{n^2} n = \frac{2^n}{n}, \quad 2^{n-k} < \frac{2^{n+1}}{n - 2 \log_2 n} = O\left(\frac{2^n}{n}\right).$$

同时 $k 2^k = O(n \log n) = O(2^n/n)$, 故 式 (2.1) 为 $O(2^n/n)$ 。有限多个较小的 n 可以吸收到大 O 的常数中。最后对 m 个输出位分别使用这一构造, 即得

$$|C| = O\left(\frac{m 2^n}{n}\right).$$

□

2.3.4 计数下界

下面用计数论证 (counting argument) 说明上述关于 n 的上界不能继续改进到更低的数量级。

命题 2.1 (布尔函数的电路下界). 存在常数 $c_0 > 0$, 使得对所有充分大的 n , 都有某个函数 $f: \{0, 1\}^n \rightarrow \{0, 1\}$ 的任意布尔电路至少需要

$$c_0 \frac{2^n}{n}$$

个逻辑门。

证明. 一共有

$$2^{2^n}$$

个函数 $\{0, 1\}^n \rightarrow \{0, 1\}$ 。另一方面, 设一个 NAND-Circ 程序至多有 s 行, 并考虑 $s \geq n$ 的情形。程序中至多出现 $n + s \leq 2s$ 个值。即使把每行都宽松地记为一个三元组, 并把所有不合法的三元组序列也计算在内, 仍存在常数 $c \geq 1$, 使这类程序的数量至多为

$$2^{cs \log_2 s}.$$

取

$$s = \left\lfloor \frac{2^n}{2cn} \right\rfloor.$$

当 n 充分大时, $s \geq n$ 且 $\log_2 s \leq n$, 所以

$$cs \log_2 s \leq 2^{n-1}, \quad 2^{cs \log_2 s} < 2^{2^n}.$$

程序少于函数, 故至少有一个函数不能由 s 行以内的 NAND-Circ 程序计算。再由 NAND 门与 AND、OR、NOT 门之间的常数规模转换, 结论成立。□

因此, 定理 2.2 给出的 $O(2^n/n)$ 单输出上界在常数因子意义下是紧的。

2.4 程序编码与通用求值

下面约定 $s \geq \max\{n, m, 2\}$ 。一个含 s 行、 n 个输入和 m 个输出的 NAND-Circ 程序至多需要 $3s$ 个变量。把它们依次编号为

$$v_0, v_1, \dots, v_{3s-1},$$

其中 $v_0, \dots, v_{n-1}$ 存放输入, $v_n, \dots, v_{n+m-1}$ 存放输出。每行程序编码为三元组

$$(a, b, c), \quad v_a \leftarrow \text{NAND}(v_b, v_c).$$

令 $\ell = \lceil \log_2(3s) \rceil$ 。每个下标用 ℓ 位表示, 故整个程序可以编码为长度 $3s\ell$ 的二进制串。

例 2.4 (通用求值函数). 定义通用求值函数 (universal evaluation function)

$$\text{EVAL}_{s,n,m} : \{0, 1\}^{3s\ell+n} \longrightarrow \{0, 1\}^m.$$

输入写成 (p, x) , 其中 p 是一个程序编码, $x \in \{0, 1\}^n$ 。规定

$$\text{EVAL}_{s,n,m}(p, x) = \begin{cases} P(x), & p \text{ 编码了合法程序 } P, \\ 0^m, & \text{否则.} \end{cases}$$

定理 2.3 (通用 NAND-Circ 程序). 对任意 $s \geq \max\{n, m, 2\}$, 都存在计算 $\text{EVAL}_{s,n,m}$ 的 NAND-Circ 程序 $U_{s,n,m}$, 并且

$$|U_{s,n,m}| = O(s^2 \log s).$$

证明. 以下出现的 LOOKUP、MUX 与等值测试都按前文展开为 NAND 门。用 $V \in \{0, 1\}^{3s}$ 保存被模拟程序的全部变量值。首先令

$$V^{(0)} = (x_0, \dots, x_{n-1}, 0, \dots, 0).$$

对一个用 ℓ 位表示的下标 i , 将 V 补零到长度 2^ℓ , 再调用 例 2.3, 即可实现

$$\text{GET}(V, i) = V_i$$

, 代价为 $O(2^\ell) = O(s)$ 。更新操作逐坐标定义为

$$\text{UPDATE}(V, i, z)_j = \text{MUX}(\text{EQ}_\ell(i, j), V_j, z), \quad 0 \leq j < 3s,$$

其中 EQ_ℓ 是 ℓ 位等值测试 (equality test), 可用 $O(\ell) = O(\log s)$ 个门实现。因此

$$|\text{UPDATE}| = O(s \log s).$$

若程序的第 t 行编码为 (a_t, b_t, c_t) , 则依次计算

$$\begin{aligned} r_t &= \text{GET}(V^{(t-1)}, b_t), \\ q_t &= \text{GET}(V^{(t-1)}, c_t), \\ z_t &= \text{NAND}(r_t, q_t), \\ V^{(t)} &= \text{UPDATE}(V^{(t-1)}, a_t, z_t). \end{aligned}$$

每轮使用 $O(s \log s)$ 个门, 模拟 s 行共需 $O(s^2 \log s)$ 个门。同时维护“变量是否已经定义”的比特, 并检查下标范围、读取顺序和输出是否已定义, 只会使轮多出常数次 GET、UPDATE 与等值测试。最后用合法性比特屏蔽输出: 合法时输出 $V_n^{(s)}, \dots, V_{n+m-1}^{(s)}$, 否则输出 0^m 。总规模仍为 $O(s^2 \log s)$ 。□

思考题. 能否把定理 2.3 的规模改进到 $O(s \log s)$?

第 3 章 布尔函数与语言

3.1 从一般函数到布尔函数

一般的计算问题是函数

$$f : \{0, 1\}^* \longrightarrow \{0, 1\}^*.$$

事实上，只研究取值于 $\{0, 1\}$ 的布尔函数并不会损失一般性。给定 f ，定义它的逐位查询函数

$$b_f : \{0, 1\}^* \times \mathbb{N} \times \{0, 1\} \longrightarrow \{0, 1\}$$

如下：

$$b_f(x, i, c) = \begin{cases} f(x)_i, & i < |f(x)| \text{ 且 } c = 0, \\ 1, & i < |f(x)| \text{ 且 } c = 1, \\ 0, & i \geq |f(x)|. \end{cases} \quad (3.1)$$

这里从 0 开始给输出位编号。自然数 i 和三元组 (x, i, c) 均使用固定的二进制编码；具体选用哪一种合理编码，不影响下面的可计算性结论。

引理 3.1 (逐位查询与原函数等价). 函数 f 可计算，当且仅当 b_f 可计算。

证明. 若有计算 f 的程序，先算出 $y = f(x)$ ，再按 [式 \(3.1\)](#) 回答查询，即可计算 b_f 。

反过来，注意到

$$b_f(x, i, 1) = 1 \iff i < |f(x)|, \quad f(x)_i = b_f(x, i, 0) \quad (i < |f(x)|).$$

从 $i = 0$ 开始依次查询 $b_f(x, i, 1)$ 。只要结果为 1，就把 $b_f(x, i, 0)$ 追加到输出；第一次得到 0 时停止。所得字符串恰为 $f(x)$ 。□

因此，讨论一般字符串函数的可计算性，可以归约为讨论布尔函数的可计算性。

3.2 语言与布尔函数

定义 3.1 (语言与示性函数). 一个语言 (language) 是二进制串集合 $A \subseteq \{0, 1\}^*$ 。对布尔函数 $f: \{0, 1\}^* \rightarrow \{0, 1\}$, 定义

$$A_f = \{x \in \{0, 1\}^* : f(x) = 1\}.$$

反过来, 语言 A 的示性函数 (characteristic function) 定义为

$$\chi_A(x) = \begin{cases} 1, & x \in A, \\ 0, & x \notin A. \end{cases}$$

上述两个变换互为逆映射。因此布尔函数与语言一一对应, 并且

$$f(x) = 1 \iff x \in A_f.$$

第 4 章 自动机

自动机 (automaton) 用有限状态描述对输入串的逐位计算。本章先研究确定有限自动机, 再引入非确定有限自动机。


4.1 确定有限自动机

例 4.1 (奇偶校验). 对 $x = x_0x_1 \cdots x_{n-1} \in \{0, 1\}^*$, 定义

$$\text{PARITY}(x) = x_0 \text{ xor } x_1 \text{ xor } \cdots \text{ xor } x_{n-1}.$$

并约定 $\text{PARITY}(\varepsilon) = 0$ 。

下面的自动机中, q_0 表示目前读到偶数个 1, q_1 表示目前读到奇数个 1。接受状态为 q_1 。



定义 4.1 (确定有限自动机). 一个确定有限自动机 (deterministic finite automaton, DFA) 是四元组

$$M = (K, s, F, \delta),$$

其中:

1. K 是有限的状态集合 (state set);
2. $s \in K$ 是初始状态 (initial state);
3. $F \subseteq K$ 是接受状态 (accepting state) 的集合;
4. $\delta: K \times \{0, 1\} \rightarrow K$ 是转移函数 (transition function)。

对输入 $x = x_0x_1 \cdots x_{n-1}$, 自动机产生状态序列

$$s_0 = s, \quad s_{i+1} = \delta(s_i, x_i) \quad (0 \leq i < n).$$

若 $s_n \in F$, 则称 M 接受 x ; 否则称 M 拒绝 x 。

定义 4.2 (计算函数与判定语言). 设 $f: \{0, 1\}^* \rightarrow \{0, 1\}$, $A \subseteq \{0, 1\}^*$ 。

- 如果对每个 x , M 接受 x 当且仅当 $f(x) = 1$, 则称 M 计算 f ;
- 如果对每个 x , M 接受 x 当且仅当 $x \in A$, 则称 M 判定 A 。

定义 4.3 (DFA 的语言与正则语言). DFA M 接受的全部字符串构成它的语言

$$L(M) = \{x \in \{0, 1\}^* : M \text{ 接受 } x\}.$$

如果存在 DFA M 使得 $A = L(M)$, 则称语言 A 是正则的 (regular)。相应地, 若 A_f 正则, 则称布尔函数 f 是正则的。

命题 4.1. 存在非正则语言。

证明. 每个 DFA 都能编码为有限二进制串, 所以全部 DFA 至多可数。另一方面, 全部语言不可数: 若能把它们枚举为 $A_0, A_1, A_2, \dots$, 并把 $\{0, 1\}^*$ 枚举为 $w_0, w_1, w_2, \dots$, 则语言

$$D = \{w_i : w_i \notin A_i\}$$

与每个 A_i 都不同, 矛盾。因此必有语言不能被任何 DFA 判定。 $\square$

4.2 正则语言的封闭性

定理 4.1 (对并集封闭). 若 A 和 B 都是正则语言, 则 $A \cup B$ 也是正则语言。

证明. 设

$$M_A = (K_A, s_A, F_A, \delta_A), \quad M_B = (K_B, s_B, F_B, \delta_B)$$

分别判定 A 和 B 。构造乘积自动机 $M = (K, s, F, \delta)$, 其中

$$K = K_A \times K_B,$$

$$s = (s_A, s_B),$$

$$F = (F_A \times K_B) \cup (K_A \times F_B),$$

$$\delta((q_A, q_B), a) = (\delta_A(q_A, a), \delta_B(q_B, a)).$$

归纳可知, M 读完任意输入 x 后的两个状态分量, 恰好分别是 M_A 与 M_B 读完 x 后的状态。因此

$$M \text{ 接受 } x \iff M_A \text{ 接受 } x \text{ 或 } M_B \text{ 接受 } x \iff x \in A \cup B.$$

□

对语言 $A, B \subseteq \{0, 1\}^*$, 定义它们的拼接 (concatenation) 为

$$AB = \{xy : x \in A, y \in B\}.$$

定理 4.2 (对拼接封闭). 若 A 和 B 都是正则语言, 则 AB 也是正则语言。

直接用 DFA 构造拼接并不方便。完整证明将在后文给出; 这里先引入 NFA。

4.3 非确定有限自动机

与 DFA 相比, NFA 可以从同一状态沿同一输入转移到多个状态, 也可以进行不消耗输入符号的 ε -转移。

定义 4.4 (非确定有限自动机). 一个非确定有限自动机 (nondeterministic finite automaton, NFA) 是四元组

$$N = (K, s, F, \Delta),$$

其中 K, s, F 与 DFA 中的含义相同, 而转移关系满足


$$\Delta \subseteq K \times (\{0, 1\} \cup \{\varepsilon\}) \times K.$$

NFA 接受字符串 x , 是指存在一条从 s 到某个接受状态的路径, 使得路径标签依次串联并删除所有 ε 后恰好得到 x 。

例 4.2. 语言

$$A = \{w \in \{0, 1\}^* : |w| \geq 2 \text{ 且 } w \text{ 的倒数第二位为 } 1\}$$

可以由下面的 NFA 判定。在状态 q_0 读到 1 时, 自动机既可以留在 q_0 , 也可以猜测这个 1 是倒数第二位并转移到 q_1 ; 若随后恰好再读一个比特, 便会到达接受状态。



4.3.1 NFA 与 DFA 的等价性

定理 4.3 (NFA 与 DFA 等价). 对每个 NFA, 都存在一个接受相同语言的 DFA; 反之亦然。

证明. DFA 是每一步都只有唯一后继状态、且没有 ε -转移的特殊 NFA, 故一个 DFA 可以直接看作 NFA。

反过来, 设 NFA 为 $N = (K, s, F, \Delta)$ 。对 $S \subseteq K$, 记 $E(S)$ 为从 S 中某个状态出发, 只经过有限次 ε -转移所能到达的全部状态。构造 DFA

$$D = (\mathcal{P}(K), E(\{s\}), F_D, \delta_D),$$

其中 $\mathcal{P}(K)$ 是 K 的幂集 (power set), 并令

$$F_D = \{S \subseteq K : S \cap F \neq \emptyset\},$$

$$\delta_D(S, a) = E(\{q' \in K : \text{存在 } q \in S, (q, a, q') \in \Delta\}).$$

这个构造称为状态子集构造 (subset construction)。对输入长度归纳可知, D 读完任意字符串 x 后所处的状态, 恰好是 N 读完 x 后所有可能状态的集合。因此该集合与 F 相交, 当且仅当 N 有一条接受 x 的计算路径。又因为 K 有限, $\mathcal{P}(K)$ 也有限, 所以 D 确实是 DFA。□

推论 4.1. 一个语言是正则语言, 当且仅当它能被某个 NFA 判定。

证明. 由定义 4.3 和定理 4.3 立即得到。□

4.3.2 拼接与 Kleene 星

定理 4.2 的证明. 取分别判定 A 和 B 的 NFA

$$N_A = (K_A, s_A, F_A, \Delta_A), \quad N_B = (K_B, s_B, F_B, \Delta_B),$$

不妨设 $K_A \cap K_B = \emptyset$ 。构造 NFA

$$N = (K_A \cup K_B, s_A, F_B, \Delta),$$

其中

$$\Delta = \Delta_A \cup \Delta_B \cup \{(q, \varepsilon, s_B) : q \in F_A\}.$$

也就是说, 从 N_A 的每个接受状态增加一条到 N_B 初始状态的 ε -转移。于是 N 接受 w , 当且仅当可以把 w 写成 $w = xy$, 使得 N_A 接受 x 且 N_B 接受 y 。因此 $L(N) = AB$, 再由推论 4.1 可知 AB 正则。□

对语言 A , 递归定义 $A^0 = \{\varepsilon\}$ 、 $A^{n+1} = A^n A$, 并称

$$A^* = \bigcup_{n \geq 0} A^n$$

为 A 的 Kleene 星 (Kleene star)。

定理 4.4 (对 Kleene 星封闭). 若 A 是正则语言, 则 A^* 也是正则语言。

证明. 取判定 A 的 NFA $N_A = (K, s, F, \Delta)$, 并增加一个新状态 s' 。令

$$\begin{aligned} K' &= K \cup \{s'\}, \\ F' &= F \cup \{s'\}, \\ \Delta' &= \Delta \cup \{(s', \varepsilon, s)\} \cup \{(q, \varepsilon, s) : q \in F\}. \end{aligned}$$

则 $N' = (K', s', F', \Delta')$ 可以先从 s' 进入 N_A , 并在每次到达 N_A 的接受状态后重新开始新一轮。新初态 s' 本身是接受状态, 所以 N' 也接受空串。因此 $L(N') = A^*$, 由推论 4.1 可知 A^* 正则。 $\square$

4.4 正则表达式

定义 4.5 (正则表达式). 二进制字母表上的正则表达式 (regular expression) 按下面的规则递归定义:

1. $\emptyset$ 、0 和 1 是正则表达式, 它们分别描述语言 $\emptyset$ 、 $\{0\}$ 和 $\{1\}$;
2. 如果 R_1, R_2 是正则表达式, 那么 $R_1 \cup R_2$ 和 $R_1 R_2$ 也是正则表达式, 并且

$$L(R_1 \cup R_2) = L(R_1) \cup L(R_2), \quad L(R_1 R_2) = L(R_1) L(R_2);$$

3. 如果 R 是正则表达式, 那么 R^* 也是正则表达式, 并且

$$L(R^*) = L(R)^*.$$

在省略括号时, Kleene 星的优先级最高, 拼接次之, 并集最低。另外用 ε 作为 $\emptyset^*$ 的简写。

例 4.3. 至少含两个 0 的二进制串构成的语言可以写成

$$(0 \cup 1)^* 0 (0 \cup 1)^* 0 (0 \cup 1)^*.$$

定理 4.5 (正则表达式刻画正则语言). 一个语言是正则语言, 当且仅当它能由正则表达式描述。

证明. 先设语言由正则表达式 R 描述。对 R 的递归结构归纳: 三个基本表达式描述的语言都是正则的; 归纳步骤则分别由正则语言对并集、拼接和 Kleene 星的封闭性得到。因此 $L(R)$ 正则。

反过来, 设正则语言 A 由某个 NFA N 判定。先给 N 增加一个没有入边的新初态和一个没有出边的唯一新接受态: 从新初态向原初态添加 ε -转移, 再从每个原接受态向新接受态添加 ε -转移。

把任意两个状态之间的所有边合并为一条边, 并用这些边标签的并集作为新标签; 没有边时, 标签记为 $\emptyset$ 。随后逐个删除初态与接受态之外的状态。删除状态 q 时, 对每对保留的状态 p, r , 将边 $p \rightarrow r$ 的标签更新为

$$R_{pr} \cup R_{pq}(R_{qq})^*R_{qr}.$$

该式分别涵盖了不经过 q 的路径, 以及进入 q 、在 q 处循环有限次后离开的路径。归纳可知, 每次删除后, 边标签仍描述原自动机中相应的全部路径。最后只剩新初态和新接受态, 两者之间的边标签就是一个描述 A 的正则表达式。□